Mohamed Yassine Ben Romdhane

INGÉNIEUR IA & FULL-STACK

+216 54 134 306 | yassine.ben.romdhanee@gmail.com | Monastir, Tunisie
yassine-ben-romdhane.vercel.app | github.com/Yassine2606

PROFIL

Ingénieur IA et full-stack (ESPRIM, 2026), spécialisé en systèmes RAG et en plateformes web/mobile. Conception d'un assistant documentaire à réponses sourcées chez Capgemini Engineering (FastAPI, pgvector, routage de LLM entre plusieurs fournisseurs). Développe des interfaces React et React Native s'appuyant sur Node.js, Python et PostgreSQL.

COMPÉTENCES TECHNIQUES

Langages : TypeScript, JavaScript, Python, SQL
Frontend : React, React Native, Next.js, Angular, Tailwind CSS, Expo
Backend : Node.js, Express, Fastify, FastAPI, Spring Boot, API REST
IA & Data : RAG, LLM, embeddings, pgvector, recherche hybride, tool calling, Gemini, NVIDIA NIM, scikit-learn
Bases de données : PostgreSQL, MongoDB, Redis, Supabase
Outils : Docker, Docker Compose, Git, Socket.IO, MQTT

EXPÉRIENCE PROFESSIONNELLE

Stagiaire ingénieur IA — Capgemini Engineering — févr. 2026 – juin 2026
Stage de fin d'études · Assistant documentaire à réponses sourcées (RAG)

- Développement d'un assistant RAG (Retrieval-Augmented Generation) qui répond à des questions en langage naturel sur des documents en 4 formats — PDF, DOCX, Markdown et exports wiki — en citant les sources exactes de chaque réponse.
- Conception d'un backend en 2 services — une API Node.js/Express pour l'authentification et l'orchestration des conversations, un service Python/FastAPI pour le parsing, le chunking, les embeddings et la recherche — avec PostgreSQL + pgvector comme stockage partagé.
- Mise en place d'une recherche hybride (vectorielle + plein texte, fusion RRF) et d'une passe de vérification qui confronte chaque réponse aux preuves récupérées et rejette les réponses non étayées.
- Routage des LLM entre 2 fournisseurs (NVIDIA NIM pour la génération et les tool calls, Gemini pour les résumés), nouvelles tentatives avec réécriture des requêtes et gestion des erreurs de streaming.
- 11 scénarios de bout en bout validés (contrôle d'accès, attribution des sources, bascule entre fournisseurs, streaming), avec une latence médiane de 1,9 s sur un corpus de 18 documents lors de tests locaux.

Ingénieur full-stack et mobile — YBInnovations — 2025
Projet · Wave, plateforme communautaire pour étudiants et associations

- Développement d'une application multiplateforme Expo/React Native avec 6 modules : événements, covoiturage, logement, tutorat, bons plans et messagerie temps réel.
- Conception d'une API TypeScript/Express sur PostgreSQL et MongoDB, avec authentification JWT et cloisonnement des données par utilisateur.
- Pipeline de notifications push adossé à Redis et intégration des paiements Lydia avec gestion des webhooks.
- Mise en place de la messagerie temps réel Socket.IO et de la gestion d'état sur les 6 modules.

Développeur full-stack et data — MyMatch — 2024
Projet · Plateforme de réservation et de gestion de matchs de football

- Développement d'API REST pour 3 flux métier : authentification, réservations et gestion des matchs.
- Mise en place de recommandations de matchs à partir des données des joueurs et des rencontres, avec optimisation des requêtes en base.
- Développement de modules frontend pour la réservation et la gestion des matchs ; contribution à la conception du schéma de données et à l'optimisation des requêtes.

FORMATION

Diplôme d'ingénieur en informatique — parcours Data Science (2023 – 2026)
ESPRIM — École Supérieure Privée d'Ingénieurs de Monastir
Diplôme national d'ingénieur ; projet de fin d'études chez Capgemini Engineering.

LANGUES

Arabe (langue maternelle) · Français (courant) · Anglais (courant)