Mohamed Yassine Ben Romdhane

INGÉNIEUR IA & FULL-STACK

+216 54 134 306

yassine.ben.romdhanee@gmail.com

Monastir, Tunisie

yassine-ben-romdhane.vercel.app

github.com/Yassine2606

FORMATION

Diplôme d'ingénieur en informatique — parcours Data Science

ESPRIM — École Supérieure Privée d'Ingénieurs de Monastir · 2023 – 2026

Diplôme national d'ingénieur ; projet de fin d'études chez Capgemini Engineering.

COMPÉTENCES TECHNIQUES

Langages

TypeScript, JavaScript, Python, SQL

Frontend

React, React Native, Next.js, Angular, Tailwind CSS, Expo

Backend

Node.js, Express, Fastify, FastAPI, Spring Boot, API REST

IA & Data

RAG, LLM, embeddings, pgvector, recherche hybride, tool calling, Gemini, NVIDIA NIM, scikit-learn

Bases de données

PostgreSQL, MongoDB, Redis, Supabase

Outils

Docker, Docker Compose, Git, Socket.IO, MQTT

LANGUES

Arabe	langue maternelle
Français	courant
Anglais	courant

PROFIL

Ingénieur IA et full-stack (ESPRIM, 2026), spécialisé en systèmes RAG et en plateformes web/mobile. Conception d'un assistant documentaire à réponses sourcées chez Capgemini Engineering (FastAPI, pgvector, routage de LLM entre plusieurs fournisseurs). Développe des interfaces React et React Native s'appuyant sur Node.js, Python et PostgreSQL.

EXPÉRIENCE PROFESSIONNELLE

Stagiaire ingénieur IA — Capgemini Engineering — févr. 2026 – juin 2026

Stage de fin d'études · Assistant documentaire à réponses sourcées (RAG)

- Développement d'un assistant RAG (Retrieval-Augmented Generation) qui répond à des questions en langage naturel sur des documents en 4 formats — PDF, DOCX, Markdown et exports wiki — en citant les sources exactes de chaque réponse.
- Conception d'un backend en 2 services — une API Node.js/Express pour l'authentification et l'orchestration des conversations, un service Python/FastAPI pour le parsing, le chunking, les embeddings et la recherche — avec PostgreSQL + pgvector comme stockage partagé.
- Mise en place d'une recherche hybride (vectorielle + plein texte, fusion RRF) et d'une passe de vérification qui confronte chaque réponse aux preuves récupérées et rejette les réponses non étayées.
- Routage des LLM entre 2 fournisseurs (NVIDIA NIM pour la génération et les tool calls, Gemini pour les résumés), nouvelles tentatives avec réécriture des requêtes et gestion des erreurs de streaming.
- 11 scénarios de bout en bout validés (contrôle d'accès, attribution des sources, bascule entre fournisseurs, streaming), avec une latence médiane de 1,9 s sur un corpus de 18 documents lors de tests locaux.

Ingénieur full-stack et mobile — YBInnovations — 2025

Projet · Wave, plateforme communautaire pour étudiants et associations

- Développement d'une application multiplateforme Expo/React Native avec 6 modules : événements, covoiturage, logement, tutorat, bons plans et messagerie temps réel.
- Conception d'une API TypeScript/Express sur PostgreSQL et MongoDB, avec authentification JWT et cloisonnement des données par utilisateur.
- Pipeline de notifications push adossé à Redis et intégration des paiements Lydia avec gestion des webhooks.
- Mise en place de la messagerie temps réel Socket.IO et de la gestion d'état sur les 6 modules.

Développeur full-stack et data — MyMatch — 2024

Projet · Plateforme de réservation et de gestion de matchs de football

- Développement d'API REST pour 3 flux métier : authentification, réservations et gestion des matchs.
- Mise en place de recommandations de matchs à partir des données des joueurs et des rencontres, avec optimisation des requêtes en base.
- Développement de modules frontend pour la réservation et la gestion des matchs ; contribution à la conception du schéma de données et à l'optimisation des requêtes.